

MBA em Tecnologia para Negócios: AI, Data Science e Big Data

PUCRS online  UOL edtech.

ContextLab: Engenharia de Contexto para Assistentes de IA Empresariais

MODELAGEM DE NEGÓCIO

KEVIN CERQUEIRA DE ARAUJO

Orientador: Prof. Dr. Maurício Vitorino Saraiva

Porto Alegre, 2026

RESUMO

A adoção de assistentes de inteligência artificial sobre bases de conhecimento corporativas tem esbarrado em uma decisão que costuma ser tomada por moda, e não por medição: qual estratégia de contexto usar para alimentar o modelo. As empresas oscilam entre jogar toda a base no prompt, aproveitando janelas de contexto (context windows) cada vez maiores, adotar recuperação aumentada (RAG) por ser o padrão do momento, ou presumir que dados estruturados pedem um agente de SQL, e fazem isso sem comparar confiabilidade, custo e escalabilidade, o que acaba transferindo o risco para o ambiente de produção. Este trabalho apresenta a ContextLab, um serviço de diagnóstico que escolhe essa arquitetura a partir de evidência medida, e o fundamenta em um experimento controlado que compara quatro estratégias de engenharia de contexto (contexto completo, RAG semântico, um wiki no estilo GraphRAG e um agente texto-para-SQL) sobre um corpus empresarial sintético, com 40 questões congeladas, avaliação cega por um juiz mais forte e revisão por um segundo modelo, na escala de 0 a 3, somado a um estudo de escala do corpus de 1x a 3x e a um teste de viabilidade em um modelo de contexto curto. O resultado principal é que não existe um vencedor único. No corpus base, o contexto completo e o wiki empatam em acurácia (2,95), com o RAG quase no mesmo nível (2,93) e o SQL atrás (2,35); o wiki se mostra a estratégia mais robusta quando a base cresce, mantendo a acurácia praticamente estável de 2,95 para 2,85 e a melhor nota de citação (2,75) quase intacta, e o RAG é o mais econômico (US\$ 0,065 por 40 questões), enquanto o custo do contexto completo cresce de forma linear, de US\$ 1,34 para US\$ 3,34 entre 1x e 3x, e se torna inviável já em 1x num modelo de 131 mil tokens. Conclui-se que a arquitetura certa depende do tipo de tarefa e da escala do corpus, e que a recomendação para produção de alta confiabilidade é híbrida, combinando SQL para a fatia estruturada, RAG para busca local e wiki para síntese e autoridade, que é justamente a decisão que a ContextLab entrega como produto.

Palavras-chave: engenharia de contexto; RAG; GraphRAG; avaliação de modelos de linguagem; gestão do conhecimento.

ABSTRACT

The adoption of artificial-intelligence assistants over corporate knowledge bases keeps running into a decision that tends to be made by fashion rather than by measurement: which context strategy to use to feed the model. Companies swing between dumping the whole base into the prompt, taking advantage of ever-larger context windows, adopting retrieval-augmented generation (RAG) because it is the current default, or assuming that structured data calls for a SQL agent, and they do so without comparing reliability, cost, and scalability, which ends up shifting the risk to the production environment. This work presents ContextLab, a diagnostic service that chooses this architecture from measured evidence, and grounds it in a controlled experiment comparing four context-engineering strategies (full context, semantic RAG, a GraphRAG-style wiki, and a text-to-SQL agent) over a synthetic business corpus, with 40 frozen questions, blind grading by a stronger judge and a second-model review, on a 0-to-3 scale, plus a 1x-to-3x corpus-scaling study and a short-context feasibility test. The main result is that there is no single winner. On the base corpus, full context and the wiki tie on accuracy (2.95), with RAG nearly level (2.93) and SQL behind (2.35); the wiki proves to be the most robust strategy as the base grows, holding accuracy almost steady from 2.95 to 2.85 and keeping the best citation score (2.75) nearly intact, while RAG is the cheapest (US\$ 0.065 per 40 questions) and the cost of full context grows linearly, from US\$ 1.34 to US\$ 3.34 between 1x and 3x, becoming infeasible already at 1x on a 131k-token model. We conclude that the right architecture depends on the task type and the corpus scale, and that the recommendation for high-reliability production is hybrid, combining SQL for the structured slice, RAG for local lookup, and the wiki for synthesis and authority, which is precisely the decision ContextLab delivers as its product.

Keywords: context engineering; RAG; GraphRAG; large language model evaluation; knowledge management.

SUMÁRIO

APRESENTAÇÃO DA EMPRESA.....	5
DESCRIÇÃO DO PRODUTO OU SERVIÇO.....	7
SEGMENTAÇÃO DE CLIENTES.....	11
PROPOSTA DE VALOR.....	13
CANAIS DE COMUNICAÇÃO E DE DISTRIBUIÇÃO.....	17
ESTRATÉGIAS DE RELACIONAMENTO COM O CLIENTE.....	18
FONTES DE RECEITA E PRECIFICAÇÃO.....	19
RECURSOS E CAPACIDADES NECESSÁRIAS.....	21
ATIVIDADES-CHAVE REALIZADAS PELA EMPRESA.....	22
REDE DE PARCEIROS ESTRATÉGICOS.....	24
ESTRUTURA DE CUSTOS DA EMPRESA.....	26
REFERÊNCIAS.....	28
ANEXOS.....	31

1. APRESENTAÇÃO DA EMPRESA

A ContextLab é uma empresa de diagnóstico técnico orientado a evidência. Seu objeto de trabalho é uma decisão que praticamente toda média e grande empresa enfrenta hoje, no momento em que resolve adotar assistentes de inteligência artificial sobre suas próprias bases de conhecimento: qual arquitetura de contexto (context architecture) usar para que esse assistente seja, ao mesmo tempo, confiável, rastreável e sustentável em custo. A ContextLab não vende um chatbot nem uma plataforma; o que ela vende é a resposta medida a essa pergunta. Para cada cliente, ela monta um benchmark sobre a base de conhecimento real do próprio cliente, implementa e mede as estratégias concorrentes de engenharia de contexto, e entrega uma recomendação de arquitetura apoiada em números, isto é, em acurácia, qualidade de citação, custo por consulta, latência e comportamento à medida que o corpus cresce.

O problema que justifica a empresa é concreto e tem custo. Hoje, as organizações vêm escolhendo a arquitetura de seus assistentes de IA por moda, e não por medição. Ora se opta por jogar a base inteira no prompt, aproveitando o fato de que os modelos modernos têm janelas de contexto (context windows) gigantescas; ora se adota recuperação aumentada (RAG) por ser o padrão do momento; ora se presume que um agente de SQL é a escolha natural porque "dados estruturados pedem SQL". Cada uma dessas decisões carrega premissas não testadas sobre confiabilidade, custo e escalabilidade, e essas premissas só se revelam em produção, quando o investimento já foi feito. O experimento controlado que fundamenta esta monografia dá a dimensão do erro possível: as estratégias de wiki e de SQL, quando implementadas como aproximações fracas em uma versão preliminar, alcançaram acurácia de apenas 1,63 e 0,78, e, reimplementadas conforme a prática atual, saltaram para 2,95 e 2,35 na escala de 0 a 3. Em outras palavras, o que governou o resultado foi a maturidade da implementação, e não o rótulo da estratégia, que é exatamente a nuance que uma decisão tomada por hype tende a ignorar.

Vale notar que o problema, na sua raiz, é de gestão do conhecimento, e não apenas de tecnologia. Conhecimento organizacional não se confunde com um repositório de documentos: ele envolve a conversão contínua entre conhecimento tácito e explícito, e precisa ser articulado e amplificado pela organização para gerar

valor (NONAKA, 1994). Davenport e Prusak (1998) distinguem dados, informação e conhecimento, e tratam a gestão do conhecimento como uma prática organizacional que envolve pessoas, processos e curadoria, e não como um produto que se compra pronto. Uma base documental grande e desorganizada confunde informação com conhecimento, e jogá-la inteira em um modelo de linguagem não resolve esse problema, apenas o transfere para o momento da inferência. Por isso, a pergunta de arquitetura da ContextLab é também uma pergunta sobre quanta curadoria vale a pena construir sobre a base antes de expô-la a um modelo.

Há ainda um risco específico dos modelos de linguagem que transforma a escolha de arquitetura em uma questão de confiabilidade, e não de preferência. Os modelos de linguagem produzem texto fluente e convincente mesmo quando não têm fundamento factual, e a alucinação é um problema recorrente e bem documentado da geração de linguagem natural (JI et al., 2023). Pior ainda, avaliações binárias de "certo ou errado" escondem respostas que misturam fatos corretos e incorretos, de modo que a factualidade precisa ser medida em granularidade fina para ser confiável (MIN et al., 2023). Em um assistente empresarial, seja de suporte, jurídico, saúde ou finanças, uma resposta fluente e errada não é um inconveniente, é um passivo. A arquitetura de contexto é justamente o que ancora a resposta do modelo em fontes verificáveis e controla esse risco, e arquiteturas diferentes o controlam em graus muito diferentes: no experimento, a melhor estratégia produziu apenas uma falha em quarenta questões, enquanto a pior acumulou doze.

A ContextLab se posiciona, portanto, na interseção exata do MBA em Data Science, BI e IA aplicada a negócio, pois transforma uma decisão técnica de engenharia de contexto em uma decisão de negócio mensurável, expressa em risco de implantação, custo total de propriedade e escalabilidade da base de conhecimento. A prática de selecionar, comprimir, estruturar e avaliar o contexto entregue a um modelo de linguagem é uma disciplina de engenharia real, ainda que o rótulo "engenharia de contexto" seja mais industrial do que acadêmico, e ela se apoia em técnicas já consolidadas de adaptação de modelos sem retreinamento de parâmetros, como o projeto de prompts e a própria recuperação aumentada (LIU et al., 2023; SAHOO et al., 2024). O capítulo seguinte descreve como a ContextLab transforma essa disciplina em um serviço de diagnóstico, e os capítulos de Proposta de Valor e de Estrutura de Custos traduzem cada achado técnico em valor econômico para o cliente.

2. DESCRIÇÃO DO PRODUTO OU SERVIÇO

O serviço da ContextLab é um diagnóstico de arquitetura de contexto orientado a evidência. A premissa é simples, e contraintuitiva para boa parte do mercado: não se escolhe a arquitetura de um assistente de IA pela reputação da técnica, escolhe-se medindo as técnicas concorrentes na base de conhecimento do próprio cliente. O que se entrega não é software, é uma decisão fundamentada, ou seja, qual estratégia de contexto adotar, para quais tipos de pergunta, a que custo e com qual comportamento à medida que a base cresce. O motor desse diagnóstico é um pipeline de avaliação reproduzível que a ContextLab desenvolveu e validou em um experimento controlado, resumido nesta seção e detalhado nos Anexos. Cabe registrar desde já que o experimento usa um corpus sintético controlado, escolha metodológica que permite congelar as respostas corretas e garantir que o material adicionado não contamine o gabarito, e cuja justificativa completa está no Anexo A.

O diagnóstico compara quatro estratégias de engenharia de contexto, escolhidas porque cobrem o espaço de decisão real das empresas. A primeira é o contexto completo (full context), que coloca todo o corpus limpo no prompt e deixa o modelo responder com citações, sendo a tradução direta da ideia de "jogar tudo no prompt". A segunda é o RAG semântico (semantic RAG), que fragmenta os documentos em trechos, gera representações vetoriais (embeddings) e recupera os mais similares por cosseno, combinando a memória paramétrica do modelo com uma memória externa não paramétrica (LEWIS et al., 2020; GAO et al., 2023); sua base técnica está na recuperação densa de passagens, nos embeddings de sentença e na busca vetorial em escala (KARPUKHIN et al., 2020; REIMERS; GUREVYCH, 2019; JOHNSON; DOUZE; JÉGOU, 2019). A terceira é o wiki no estilo GraphRAG, que constrói, em tempo de construção, um conjunto fixo de nós que preservam fatos e citam suas seções de origem, e percorre esse grafo de forma agêntica e limitada na hora de responder, alinhando-se à literatura de recuperação aumentada por grafos e de sumarização hierárquica para reduzir a perda de síntese em textos longos (EDGE et al., 2024; WANG et al., 2024; SARTHI et al., 2024; PENG et al., 2025). A quarta é o agente texto-para-SQL (text-to-SQL), que carrega as tabelas reais do corpus em um banco relacional e usa um agente para escrever, executar e autocorrigir consultas SQL, seguindo a tarefa clássica de tradução de linguagem natural para SQL (YU et

al., 2018; LI et al., 2023; RAJKUMAR; LI; BAHDANAU, 2022). Selecionar, comprimir e estruturar o contexto dessas quatro formas é, no fim das contas, a disciplina técnica que a ContextLab domina e vende (SAHOO et al., 2024).

O diferencial metodológico, e o que dá credibilidade ao laudo, está na forma de avaliação. As quatro estratégias compartilham o mesmo corpus, o mesmo conjunto de 40 questões congeladas (que cobrem busca direta de fato, citação, síntese entre documentos, comparação, orientação procedural, contradição e atualidade, questões estruturadas e recomendação de negócio), o mesmo modelo primário e a mesma instrução de estilo de resposta. As respostas foram avaliadas às cegas por Claude Sonnet, um modelo de linguagem mais forte do que o modelo sob teste, contra um conjunto de critérios definidos pelo autor, ou seja, a resposta esperada, as fontes exigidas e os fatos canônicos de cada questão, na escala de 0 a 3 para acurácia, completude, citação, utilidade e tratamento de risco. Todas as linhas sinalizadas foram depois revisadas por Claude Opus como segundo modelo. Nenhuma pessoa avaliou ou auditou as respostas do v1. O uso de um modelo de linguagem como juiz oferece escala, mas exige critérios explícitos e controles de viés (ZHENG et al., 2023; WANG et al., 2023); a ausência de calibração humana permanece uma ameaça à validade. A avaliação separa a relevância e a fidelidade ao contexto da qualidade final da resposta (ES et al., 2024; MIN et al., 2023). O desenho do benchmark, com casos controlados e documentos distratores, segue a tradição de teste comportamental que vai além da acurácia agregada (RIBEIRO et al., 2020).

O laudo entrega métricas diretamente comparáveis. A Tabela 1 resume a comparação base no tamanho original do corpus. O contexto completo e o wiki alcançam a maior acurácia (2,95), com o RAG praticamente empatado (2,93) e o SQL atrás (2,35); o wiki, porém, obtém a melhor nota de citação (2,75) e a maior utilidade (2,95) custando, em tempo de execução, cerca de um onze avos do contexto completo, ou seja, US\$ 0,123 contra US\$ 1,336 por 40 questões. Esse é o tipo de assimetria que só a medição revela, já que a estratégia mais cara não é a melhor, e a mais barata, o RAG a US\$ 0,065, fica a dois centésimos de ponto da melhor em acurácia.

Tabela 1. Comparação base das quatro estratégias (corpus 1x, 40 questões, escala de 0 a 3).

Estratégia	Acurácia	Compleitude	Citação	Utilidade	Risco	Custo (40q)	Latência
Contexto completo	2,95	2,88	2,67	2,93	2,93	US\$ 1,336	4,3 s
RAG semântico	2,93	2,83	2,70	2,90	2,93	US\$ 0,065	2,3 s
Wiki (GraphRAG)	2,95	2,85	2,75	2,95	2,93	US\$ 0,123	3,8 s
SQL (texto-para-SQL)	2,35	2,03	1,63	2,23	2,35	US\$ 0,107	3,0 s

Fonte: elaborado pelo autor com base nos resultados do experimento.

Além das médias, o diagnóstico entrega uma análise de falhas que diz ao cliente por que uma arquitetura erra, e não apenas o quanto ela erra. Cada resposta incorreta é atribuída a um de quatro modos, que são recuperação, raciocínio, ingestão ou citação. O wiki apresenta o perfil mais limpo, com uma única falha em 40 questões, e o contexto completo fica quase tão limpo, com duas. As falhas do RAG concentram-se em citação, seis de oito, refletindo casos em que o trecho certo foi recuperado, mas citado de forma imprecisa. As falhas do SQL concentram-se em recuperação, dez de doze, porque o seu recurso de busca textual deixa de encontrar fatos que vivem em prosa narrativa, e não em tabelas. Essa atribuição é corroborada pela taxa de acerto da fonte exigida: 1,00 para o contexto completo, 0,775 para o wiki, 0,70 para o RAG e 0,425 para o SQL. Para o cliente, saber que o erro do RAG é de citação, e portanto corrigível com um melhor prompt de atribuição, e que o erro do SQL é estrutural, porque o dado não está em tabela, muda completamente o plano de implantação.

A decomposição por tipo e por dificuldade de questão, mostrada nas Figuras 7 e 8, expõe o achado mais contraintuitivo do diagnóstico: o agente SQL é pior na busca direta de fato (1,5) do que nas questões projetadas para serem estruturadas (2,2). A razão é que, neste corpus, os fatos "simples", como a lista de módulos, a contagem de clientes ativos ou os detalhes de um incidente, vivem em prosa, e o armazenamento relacional não os contém. Mais ainda, nem mesmo nas questões estruturadas o SQL lidera, porque as tabelas do corpus são pequenas o bastante para serem lidas como texto pelos métodos gerais. Esse resultado refina a heurística de mercado de "usar SQL para dados estruturados", pois mostra que o valor de uma camada SQL é latente, ou seja, só se concretiza quando os dados estruturados

crescem além do que cabe no prompt. É exatamente esse tipo de conclusão acionável, e não um ranking abstrato, que a ContextLab entrega.

Para checar se essa fraqueza do SQL não era apenas uma limitação do modelo mais barato, as doze questões mais difíceis foram reexecutadas em um modelo de raciocínio mais forte. O padrão se manteve: o SQL permaneceu em torno de 2,42 de acurácia e o wiki ficou próximo do teto (2,92), o que confirma que a limitação do SQL é arquitetural, isto é, decorre de mapear um corpus majoritariamente narrativo em um esquema relacional, e não de um déficit de capacidade do modelo (Anexo D). De forma complementar, o limite de viabilidade do contexto completo foi tornado concreto ao executar o mesmo benchmark em um modelo de contexto curto, de 131 mil tokens, no qual o contexto completo falha por exceder a janela já no tamanho base, enquanto as estratégias de recuperação seguem viáveis (Anexo C). Esses dois testes, com modelos diferentes do primário, sustentam que os achados centrais não dependem de um único modelo.




Figura 7. Acurácia por categoria de questão. Contexto completo, RAG e wiki são uniformemente fortes, em torno de 3,0, em todas as categorias, e apenas o SQL se diferencia, com mínimo em busca direta de fato (1,5).




Figura 8. Acurácia por dificuldade. As três estratégias principais permanecem fortes do fácil ao difícil, ao passo que o SQL é mais fraco nas questões fáceis e não declina de forma monotônica com a dificuldade, o que confirma que o seu desempenho é governado pela resposta ser ou não tabular.

Por fim, o diagnóstico inclui um eixo de escala, isto é, como cada arquitetura se comporta quando a base de conhecimento cresce, porque é justamente nesse eixo que as decisões erradas custam mais caro. Os resultados completos do estudo de escala, de 1x a 3x, e do limite de viabilidade em modelos de contexto curto estão na Proposta de Valor (seção 4) e nos Anexos; aqui basta registrar o resumo do laudo: o wiki é a estratégia geral mais robusta à escala, com acurácia que vai de 2,95 a 2,85 e ali se estabiliza e citação em torno de 2,7 sem oscilar; o RAG é o mais econômico de ponta a ponta; e o contexto completo é uma boa linha de base que se torna inviável em custo à medida que a base cresce. A recomendação para produção é, quase sempre, híbrida, combinando SQL para a fatia estruturada, RAG para busca local barata e wiki para síntese e autoridade. Medir, e não adivinhar, é o produto.

3. SEGMENTAÇÃO DE CLIENTES

O cliente-alvo da ContextLab é a média e a grande empresa que possui uma base de conhecimento grande, crescente e crítica para a operação, e que quer construir um assistente de IA confiável sobre ela. São organizações de setores intensivos em conhecimento documental, como suporte técnico e atendimento, jurídico, saúde, finanças e educação corporativa. Nesses contextos, o assistente não responde a curiosidades, ele orienta decisões com consequência regulatória,

financeira ou clínica, e uma resposta fluente porém infundada passa a ser um passivo, e não um erro tolerável (JI et al., 2023). É esse público, que já sente o risco na pele, que se dispõe a pagar por medição em vez de palpite.

O recorte mais preciso do segmento vem de um achado do próprio experimento: o cliente ideal é justamente aquele cujo corpus cresce. Quando a base é pequena e estática, quase qualquer arquitetura funciona, tanto que, no corpus base, contexto completo, RAG e wiki empatam em torno de 2,93 a 2,95 de acurácia, e a escolha pouco importa. A decisão passa a importar, e a errar passa a custar caro, quando a base cresce. No estudo de escala, de 1x a 3x, o custo do contexto completo cresceu de forma linear, de US\$ 1,34 para US\$ 2,34 e depois US\$ 3,34 por 40 questões, enquanto as estratégias baseadas em recuperação permaneceram constantes, em torno de US\$ 0,06 a US\$ 0,12, e a qualidade de citação do contexto completo caiu de 2,67 para 2,05 ao ter de localizar a fonte certa em meio a muito mais texto. Em resumo, a escolha de arquitetura mais importa exatamente para quem tem corpus em expansão, e esse é o cliente da ContextLab.

Dentro da empresa-cliente, há três interlocutores com dores distintas, e o diagnóstico fala com os três. O time técnico, de engenharia de dados e de plataforma, quer saber qual arquitetura implementar e manter, e teme escolher errado e ter de refazer; a ele se entrega a recomendação técnica com a análise de falhas, mostrando, por exemplo, que as falhas do RAG são de citação e portanto corrigíveis, ao passo que as do SQL são estruturais. O dono do produto, ou da área de negócio, quer confiabilidade e rastreabilidade, ou seja, respostas com citação que sustentem uma decisão; a ele se entregam as notas de citação e o perfil de falhas, com uma falha em 40 no wiki contra doze no SQL. O patrocinador financeiro quer previsibilidade de custo; a ele se entrega a curva de custo por escala, que deixa claro que o custo do contexto completo é o único que cresce sem limite.

A natureza do problema também delimita o segmento, porque ele é, no fundo, de gestão do conhecimento. Empresas cuja base documental é grande mas desorganizada confundem informação com conhecimento, e o valor de uma camada curada de conhecimento é gerencial, e não apenas técnico (DAVENPORT; PRUSAK, 1998). Organizações que tratam o conhecimento como um ativo a ser articulado e amplificado, e não como um depósito de arquivos (NONAKA, 1994), são as que melhor capturam o valor do diagnóstico, porque a recomendação mais forte do experimento, que é investir em uma camada de conhecimento curada, o wiki, em

vez de depender de janelas de contexto cada vez maiores, é, em essência, uma recomendação de gestão do conhecimento aplicada à IA. O cliente que já entende isso compra rápido, e o que ainda não entende é educado pelos números.

Vale delimitar também quem não é o cliente ideal, para manter o foco. Empresas com base pequena e estável, ou com um caso de uso pontual e único, têm pouco a ganhar, pois para elas o contexto completo é uma linha de base barata e suficiente até que os limites de custo e de janela comecem a pesar, e um diagnóstico completo seria sobre-engenharia. O valor da ContextLab é proporcional ao tamanho e à taxa de crescimento da base e à criticidade das respostas, e é por isso que o segmento prioritário é a empresa de porte médio a grande, em setor regulado ou de alto risco, com conhecimento documental que se expande de forma contínua.

4. PROPOSTA DE VALOR

A proposta de valor da ContextLab é uma só: reduzir o risco de implantar IA escolhendo a arquitetura de contexto por métricas medidas, e não por hype. O cliente que adota a recomendação do diagnóstico compra quatro coisas mensuráveis, que são menos alucinação, melhor rastreabilidade, custo total de propriedade previsível e escala sustentável, e evita o custo de descobrir em produção que escolheu a arquitetura errada. Cada uma dessas promessas se sustenta em um número do experimento, e é essa ancoragem empírica que separa a ContextLab de uma consultoria de opinião.

O argumento central é que não existe estratégia universalmente melhor, e que a arquitetura certa depende do tipo de tarefa e da escala do corpus. O experimento prova isso de forma direta. No corpus base, três estratégias empatam em acurácia, com o contexto completo e o wiki em 2,95 e o RAG em 2,93, mas elas se separam em custo por uma ordem de grandeza: o contexto completo custa US\$ 1,336 por 40 questões, contra US\$ 0,123 do wiki e US\$ 0,065 do RAG. A Figura 1 torna esse trade-off explícito ao plotar qualidade contra custo em escala logarítmica, deixando ver que o contexto completo compra a sua qualidade a um custo dez vezes maior, enquanto as estratégias baseadas em recuperação obtêm qualidade comparável de forma barata. O primeiro valor que a ContextLab entrega é, portanto, evitar pagar caro por uma qualidade que se obtém barato, economia que, no corpus base, chega a cerca de 11 vezes ao se preferir o wiki ao contexto completo.




Figura 1. Qualidade (acurácia e citação) versus custo de execução, em escala logarítmica. As estratégias de recuperação ocupam o canto desejável, de alta qualidade e baixo custo, enquanto o contexto completo entrega qualidade alta a um custo uma ordem de grandeza maior.

O segundo valor é a rastreabilidade, que, em um assistente empresarial, é o que torna a resposta auditável e, portanto, utilizável em contexto regulado. Aqui o wiki se destaca de forma clara e estável, pois obtém a melhor nota de citação no corpus base (2,75) e a mantém praticamente intacta sob crescimento do corpus, indo de 2,75 a 2,70 e 2,73, enquanto a citação do contexto completo se degrada de 2,67 para 2,05 ao ter de localizar a fonte correta em meio a muito mais texto, num efeito de perda no meio do contexto (lost-in-the-middle) já bem documentado na literatura (LIU et al., 2024). O wiki entrega isso porque comprime o corpus em um número fixo de nós que preservam fatos e citam as suas fontes, e percorre esse grafo de forma curada e sensível à autoridade (EDGE et al., 2024; WANG et al., 2024). Para o cliente, citação estável sob escala significa que o assistente continua auditável à medida que a base cresce, garantia que o contexto completo não oferece.

O terceiro valor é a previsibilidade de custo e a viabilidade em escala, e é aqui que o achado mais forte do estudo se converte em argumento de negócio. A fraqueza do contexto completo ao crescer não é a acurácia, é o custo, que cresce de forma linear, de US\$ 1,34 para US\$ 2,34 e depois US\$ 3,34 por 40 questões, à medida que a entrada vai de 131 mil para 332 mil tokens, e é também a viabilidade. Em um modelo com janela de 131 mil tokens, o contexto completo falhou em todas as escalas,

inclusive em 1x, porque o prompt já excede a janela, enquanto o RAG permaneceu viável em 1x, 2x e 3x, como mostram a Figura 2 e a tabela de viabilidade dos Anexos. Isso confirma o que a literatura prevê, que colocar todo o corpus no prompt escala em tokens, custo e latência sem garantir um uso robusto do contexto, e que a arquitetura deve ser comparada por qualidade por custo, e não por acurácia máxima isolada (POPE et al., 2023; SARDANA et al., 2024). O valor entregue é um custo total de propriedade previsível, já que as estratégias de recuperação são imunes ao crescimento do corpus em custo, com o RAG em torno de US\$ 0,06, o wiki em torno de US\$ 0,12 e o SQL em torno de US\$ 0,09 em todas as escalas.




Figura 2. Custo por 40 questões versus escala do corpus. O custo do contexto completo cresce de forma linear com o tamanho do corpus, enquanto RAG, wiki e SQL permanecem essencialmente constantes.

O quarto valor é a escala sustentável da qualidade, e o diferencial competitivo, nesse ponto, é o wiki como a estratégia geral mais robusta. A sua acurácia move-se de 2,95 para 2,85 e ali estabiliza, e a sua taxa de acerto de recuperação se mantém, indo de 0,775 a 0,725 e voltando a 0,775, porque adicionar documentos distratores amplia o corpus bruto, mas não o conjunto fixo de nós sobre o qual o agente raciocina. Em contraste, a acurácia do RAG declina de forma suave, de 2,93 para 2,70 e 2,68, à medida que os distratores disputam as posições do topo da recuperação, efeito esperado quando cresce a massa de distratores semanticamente próximos e o recuperador permanece fixo (LIU et al., 2024); as curvas completas de acurácia, citação e recuperação por escala estão nas Figuras 3 a 5, nos Anexos. A

recomendação acionável que decorre disso é forte: investir em uma camada de conhecimento curada, o wiki, rende mais, à medida que a base cresce, do que depender de janelas de contexto cada vez maiores, e essa é uma decisão que muda a estratégia de dados do cliente, e não apenas um parâmetro técnico (LEWIS et al., 2020; GAO et al., 2023).

A Tabela 2 condensa o que o cliente recebe como recomendação, e é o entregável de maior valor do diagnóstico. Note-se que ela não aponta um vencedor único, mas um mapa de tarefa para arquitetura, que culmina na recomendação híbrida para produção de alta confiabilidade, combinando SQL para a fatia estruturada, RAG para busca local barata e wiki para síntese e autoridade. O agente SQL ilustra por que o híbrido importa, pois ele não deu vantagem de acurácia até o dado estruturado superar o tamanho do prompt, tendo sido o pior na busca direta de fatos em prosa (1,5), mas o seu valor é latente e se concretiza quando há milhares de linhas de métricas ou de transações, ponto em que a consulta determinística deixa de ser conveniente e passa a ser necessária. Esse é o espelho exato do problema do contexto completo: assim como o custo do contexto completo só aparece em volume, o valor do SQL também só aparece em volume.

Tabela 2. Recomendação de arquitetura por necessidade de negócio.

Necessidade de negócio	Estratégia recomendada
Corpus pequeno, protótipo rápido ou análise pontual	Contexto completo, até os limites de custo e de janela pesarem
Busca factual barata e de alto volume	RAG semântico
Síntese durável, autoridade e atualidade, melhores citações, corpus em crescimento	Wiki / GraphRAG
Contagens, métricas, preços e dashboards em formato tabular	SQL / texto-para-SQL
Produção de alta confiabilidade sobre base grande e em evolução	Híbrido (SQL + RAG + wiki), evitando contexto completo em escala

Fonte: elaborado pelo autor com base nos resultados do experimento.

A proposta de valor reconhece os seus limites, e isso reforça a sua credibilidade. As notas foram produzidas às cegas por Claude Sonnet, um modelo de linguagem mais forte do que o modelo sob teste, contra critérios definidos pelo autor. Todas as respostas sinalizadas foram revisadas por Claude Opus como segundo modelo, e esse passe confirmou as notas baixas do SQL como falhas genuínas. Nenhuma pessoa avaliou ou auditou as respostas do v1, e não houve calibração

humana. Além disso, as execuções são únicas e determinísticas, sem intervalos de confiança. Os números absolutos descrevem estas implementações de cada estratégia, e uma implementação diferente poderia deslocá-los. O que não se espera que mude são os trade-offs qualitativos, que são o custo linear do contexto completo, a robustez de escala do wiki, a economia do RAG e o valor latente do SQL, e é sobre esses trade-offs estáveis que a recomendação da ContextLab se apoia.

5. CANAIS DE COMUNICAÇÃO E DE DISTRIBUIÇÃO

Os canais da ContextLab são desenhados para um produto que vende evidência, e por isso o funil começa por demonstrar competência técnica, antes de qualquer apelo publicitário. O canal de topo é o conteúdo técnico, na forma de artigos, relatórios públicos e estudos de caso anonimizados que mostram os achados do experimento, como o fato de que o custo do contexto completo cresce de forma linear, de US\$ 1,34 para US\$ 3,34 por 40 questões entre 1x e 3x, enquanto o wiki mantém a acurácia praticamente estável, de 2,95 a 2,85. Esse conteúdo atrai exatamente o público que sente a dor, que são os times de dados e de produto em empresas com base de conhecimento crescente, e estabelece a autoridade da ContextLab sobre o tema antes de qualquer proposta comercial.

O canal de conversão é a prova de conceito, ou seja, o diagnóstico piloto. Em vez de uma venda baseada em promessa, oferece-se um diagnóstico de escopo reduzido sobre uma fatia real da base do cliente, com um subconjunto de questões e duas ou três estratégias. O piloto entrega ao cliente uma amostra concreta do laudo, como uma tabela comparativa, uma análise de falhas e uma curva de custo, e funciona como demonstração direta do valor, já que o cliente vê, nos seus próprios dados, qual arquitetura erra menos e custa menos. Como o pipeline de avaliação é o ativo reutilizável da empresa, o custo marginal de um piloto é baixo, o que o torna um canal de conversão eficiente.

As parcerias com integradores e provedores de nuvem formam o canal de escala. Integradores de sistemas que já implantam plataformas de IA empresarial precisam justificar decisões de arquitetura para os seus próprios clientes, e o diagnóstico da ContextLab é um insumo que reduz o risco dos projetos deles; os provedores de modelos e de infraestrutura, por sua vez, têm interesse em que as

implantações sobre as suas plataformas sejam confiáveis e sustentáveis. Esse canal indireto alcança clientes que a ContextLab não atingiria sozinha e alinha incentivos, pois o diagnóstico se vende como uma etapa de redução de risco dentro de um projeto maior de implantação.

A indicação é o canal de menor custo e maior conversão, e o desenho do serviço a favorece. Como o entregável é um laudo objetivo e verificável, e não uma opinião, o cliente satisfeito tem um artefato concreto para mostrar a pares de outras empresas. A natureza recorrente do relacionamento, com o diagnóstico inicial seguido de reavaliação conforme a base cresce, conforme detalhado na seção 6, também gera referências ao longo do tempo, e não apenas no fechamento do primeiro projeto.

Os quatro canais compõem um funil realista. O conteúdo técnico gera reconhecimento e qualifica interessados; o piloto converte os interessados qualificados em clientes ao provar valor nos dados deles; as parcerias ampliam o alcance por meio de projetos de terceiros; e a indicação realimenta o topo do funil com leads de alta qualidade. O fio condutor é que a ContextLab vende confiança baseada em medição, e cada canal é uma forma diferente de tornar essa medição visível antes da compra.

6. ESTRATÉGIAS DE RELACIONAMENTO COM O CLIENTE

O relacionamento da ContextLab com o cliente se estrutura em três momentos, que são o diagnóstico, o roadmap e a reavaliação contínua, e o que o torna recorrente, e não pontual, é um achado do próprio experimento: a melhor arquitetura depende da escala atual da base de conhecimento, que muda com o tempo. Avaliar a arquitetura uma única vez é insuficiente quando o corpus cresce, porque a escolha ótima migra conforme ele cresce.

O primeiro momento é o diagnóstico, descrito na seção 2. A ContextLab monta o benchmark na base do cliente, implementa e mede as estratégias e entrega o laudo comparativo com a recomendação de arquitetura. Esse é o ponto de entrada do relacionamento e o entregável que estabelece a confiança, porque o cliente vê a recomendação derivada dos seus próprios dados, com análise de falhas e curva de custo.

O segundo momento é o roadmap de implementação. A recomendação raramente é "use uma única estratégia"; para produção de alta confiabilidade sobre base grande, ela é o sistema híbrido, com SQL para a fatia estruturada, RAG para busca local e wiki para síntese e autoridade. O roadmap traduz essa recomendação em um plano de construção priorizado, sugerindo, por exemplo, começar pelo wiki, que entrega a melhor citação (2,75) e a maior robustez à escala a um custo de construção modesto, de US\$ 0,031 em chamadas de LLM, e adicionar a camada SQL apenas quando os dados estruturados crescerem além do que cabe no prompt, ponto em que o seu valor latente se concretiza.

O terceiro momento, e o que sustenta a receita recorrente, é a reavaliação contínua. A recomendação ótima é função da escala, e a base do cliente cresce, tanto que o custo do contexto completo, por exemplo, passou de US\$ 1,34 para US\$ 3,34 por 40 questões ao triplicar o corpus, e a precisão de citação do RAG cai à medida que distratores semanticamente próximos se acumulam. A ContextLab reexecuta o benchmark em intervalos definidos ou em marcos de crescimento da base, verifica se a arquitetura em produção continua sendo a melhor escolha e ajusta a recomendação. A avaliação passa, assim, a ser uma prática contínua de gestão do conhecimento, e não um evento único, e é exatamente essa continuidade que justifica a assinatura de monitoramento descrita na seção 7.

Esse desenho de relacionamento alinha o incentivo da ContextLab ao do cliente, pois a empresa só mantém a assinatura se a reavaliação continuar gerando decisões de valor, como evitar um custo crescente, manter a rastreabilidade sob escala ou antecipar o momento de adicionar a camada SQL. Como o pipeline de avaliação é reutilizável, o custo marginal de cada reavaliação é baixo, o que torna o monitoramento contínuo viável tanto para a ContextLab quanto para o cliente.

7. FONTES DE RECEITA E PRECIFICAÇÃO

A ContextLab tem três fontes de receita, e as três derivam diretamente dos três momentos do relacionamento com o cliente, descritos na seção 6. A primeira é o projeto de diagnóstico, cobrado como valor fixo; a segunda é a assinatura de monitoramento e reavaliação, de natureza recorrente; e a terceira é a consultoria de implementação do híbrido, cobrada por projeto. O princípio de precificação comum às três é cobrar pelo valor de risco evitado e de custo de inferência otimizado, e não pelo

esforço, porque o que se entrega é uma decisão de alto impacto, e não horas de trabalho.

A primeira fonte é o projeto de diagnóstico, cobrado como valor fixo por engajamento. Ele entrega o laudo comparativo completo, com as quatro estratégias medidas na base do cliente, a análise de falhas por modo, que pode ser de recuperação, raciocínio, ingestão ou citação, e a recomendação de arquitetura. O preço se ancora no risco que o cliente evita, pois escolher a arquitetura errada significa, em produção, pagar um custo de execução que cresce sem limite, como no contexto completo, cujo custo por 40 questões vai de US\$ 1,34 a US\$ 3,34 ao triplicar o corpus, ou perder rastreabilidade sob escala, com a citação do contexto completo caindo de 2,67 para 2,05, ou ainda implantar uma camada SQL que não entrega vantagem de acurácia até os dados crescerem. O diagnóstico custa uma fração do retrabalho de uma arquitetura mal escolhida.

A segunda fonte é a assinatura de monitoramento e reavaliação, que é a receita recorrente do negócio. A sua justificativa é o achado de que a arquitetura ótima depende da escala atual da base, pois, como o corpus do cliente cresce, a ContextLab reexecuta o benchmark periodicamente e mantém a recomendação atualizada. A assinatura é precificada com base no custo marginal baixo de reexecutar o pipeline, já que o ativo principal já está construído, e no valor de antecipar inflexões, como detectar o momento em que o RAG começa a perder precisão de recuperação com o acúmulo de distratores, ou em que os dados estruturados ficaram grandes o bastante para justificar a camada SQL. É uma receita que cresce com a base instalada e tem margem alta, porque reaproveita o recurso principal da empresa.

A terceira fonte é a consultoria de implementação do híbrido. A recomendação de produção de alta confiabilidade quase nunca é uma estratégia única, e sim o sistema híbrido que combina SQL, RAG e wiki. Há, portanto, demanda natural por acompanhar a construção dessa arquitetura, o que envolve definir a ordem de implantação, tipicamente o wiki primeiro, pela melhor citação e robustez de escala a um custo de construção modesto de US\$ 0,031, desenhar o roteamento entre as camadas e validar a implementação com o mesmo benchmark cego. Essa consultoria é cobrada por projeto e estende a relação para além do laudo, sem que a ContextLab precise se tornar uma fábrica de software, pois ela continua vendendo decisão e medição, agora aplicadas à implementação.

A combinação das três fontes equilibra o fluxo de caixa e os incentivos. O diagnóstico gera uma receita de entrada previsível por cliente; a assinatura gera receita recorrente de margem alta e baixa sensibilidade a custo; e a consultoria captura valor adicional nos clientes que avançam para a implementação. Em todas elas, o preço se justifica por números medidos, ou seja, quanto custa errar a arquitetura e quanto se economiza ao otimizar o custo de inferência, o que mantém a precificação defensável e alinhada à proposta de valor central de decidir por evidência, e não por hype.

8. RECURSOS E CAPACIDADES NECESSÁRIAS

O recurso principal da ContextLab é o pipeline de avaliação, que é o conjunto de harness e de scripts que monta o benchmark, executa as quatro estratégias em condições idênticas, coleta métricas de custo e de latência e organiza a avaliação cega. É esse pipeline que torna o diagnóstico reproduzível e barato de repetir, pois ele impõe os controles de justiça que dão credibilidade ao laudo, como o mesmo corpus, as mesmas questões congeladas e identificadas por hash, o mesmo modelo primário a temperatura 0 e as falhas preservadas como dado. Por ser reutilizável de cliente para cliente, ele converte o custo de construir o método, que é único, em margem alta nas reavaliações recorrentes, e é o ativo que sustenta o modelo de receita da seção 7.

O segundo recurso é o acesso a modelos e a embeddings via API. A ContextLab depende de modelos de linguagem para gerar as respostas, do modelo primário sob teste a um modelo de raciocínio mais forte usado na verificação de robustez, de um juiz mais forte para a avaliação cega e de um segundo modelo para revisar as respostas sinalizadas, e de modelos de embedding para o RAG semântico, cuja base técnica está na recuperação densa e na busca vetorial em escala (KARPUKHIN et al., 2020; REIMERS; GUREVYCH, 2019; JOHNSON; DOUZE; JÉGOU, 2019). Esse acesso é um recurso operacional crítico, e o seu custo é modesto e mensurável, tanto que a construção do wiki, por exemplo, custou US\$ 0,031 em treze chamadas de LLM, e a avaliação de um benchmark de 40 questões em quatro estratégias custa, em execução, da ordem de poucos dólares.

O terceiro recurso, e o mais escasso, é o capital humano em engenharia de contexto e de dados. O experimento deixa claro que o que governou os resultados foi

a maturidade da implementação, e não o rótulo da estratégia, pois proxies fracos de wiki e de SQL marcaram 1,63 e 0,78 de acurácia, enquanto as versões alinhadas ao estado da arte marcaram 2,95 e 2,35. Implementar um wiki que preserva fatos e cita fontes, um RAG bem calibrado e um agente texto-para-SQL que escreve e autocorrige consultas exige competência técnica real (SAHOO et al., 2024; LEWIS et al., 2020; EDGE et al., 2024; RAJKUMAR; LI; BAHIDANAU, 2022). A qualidade do diagnóstico é, no limite, a qualidade dessa equipe, e é por isso que ela é o recurso que mais diferencia a ContextLab de uma consultoria genérica.

O quarto recurso é um ativo metodológico, que é o corpus de teste sintético controlado e o seu gabarito de respostas canônicas. O corpus da empresa fictícia NovaLearn, com os seus distratores comprovadamente não contaminantes, gerados por template determinístico e sem conter nenhum número, nome ou data capaz de alterar uma resposta, permite isolar o efeito do crescimento do corpus como variável independente, num desenho de benchmark controlado e na tradição de teste comportamental que vai além da acurácia agregada (RIBEIRO et al., 2020; LIU et al., 2024). Esse ativo é o que dá à ContextLab um método validado em ambiente controlado antes de aplicá-lo à base, sempre mais ruidosa, de cada cliente, e a expertise de avaliação que ele encapsula, isto é, separar relevância e fidelidade ao contexto da qualidade da resposta e operar um modelo de linguagem como juiz apoiado em critérios e revisão, é em si um recurso (ES et al., 2024; ZHENG et al., 2023).

Esses quatro recursos se reforçam. O pipeline e o ativo metodológico tornam o método barato e defensável; o acesso a modelos é o insumo operacional; e o capital humano é o que mantém as implementações no nível de maturidade sem o qual a comparação não teria sentido. A combinação explica por que o custo marginal de um diagnóstico adicional é baixo, o que favorece o piloto como canal de conversão e a assinatura como receita recorrente, enquanto a barreira de entrada para um concorrente genérico é alta, pois ele teria de reconstruir os quatro recursos.

9. ATIVIDADES-CHAVE REALIZADAS PELA EMPRESA

As atividades-chave da ContextLab formam a cadeia que transforma a base de conhecimento do cliente em uma recomendação de arquitetura medida. São cinco,

que são montar o benchmark, implementar as estratégias, avaliar às cegas, atribuir as falhas e recomendar arquitetura e roadmap, com a reavaliação na escala fechando o ciclo. Cada uma delas é uma etapa de um método, e é a disciplina desse método, e não a opinião do consultor, que dá valor ao laudo.

A primeira atividade é montar o benchmark sobre a base do cliente. Isso significa selecionar um conjunto representativo de questões que cubram os tipos de tarefa que o assistente deverá atender, como busca direta de fato, citação, síntese entre documentos, comparação, orientação procedural, contradição e atualidade, questões estruturadas e recomendação, definir as respostas canônicas e as fontes exigidas, e congelar tudo, com os prompts e o corpus identificados por hash. Essa atividade é o que ancora a objetividade do diagnóstico, pois, sem um gabarito e um conjunto de questões fixos, qualquer comparação entre arquiteturas seria anedótica (RIBEIRO et al., 2020).

A segunda atividade é implementar as quatro estratégias em maturidade comparável. É a atividade que mais exige competência técnica e a que mais distingue o resultado, pois o experimento mostra que proxies fracos de wiki e de SQL marcaram 1,63 e 0,78, enquanto as implementações alinhadas ao estado da arte marcaram 2,95 e 2,35. Implementar significa, na prática, um RAG com fragmentação e recuperação densa bem calibradas (LEWIS et al., 2020; KARPUKHIN et al., 2020), um wiki que preserva fatos e cita fontes com travessia agêntica limitada (EDGE et al., 2024; WANG et al., 2024) e um agente texto-para-SQL que escreve, executa e autocorrige consultas (RAJKUMAR; LI; BAHDANAU, 2022; YU et al., 2018). Comparar arquiteturas só é significativo quando cada uma está no mesmo nível de maturidade.

A terceira atividade é a avaliação, que é o coração da credibilidade do serviço. No experimento v1, as respostas foram avaliadas às cegas por Claude Sonnet, um modelo de linguagem mais forte do que o modelo sob teste, contra critérios definidos pelo autor, na escala de 0 a 3. Todas as respostas sinalizadas foram revisadas por Claude Opus como segundo modelo. Nenhuma pessoa avaliou ou auditou as respostas do v1. Operar um modelo de linguagem como juiz de forma defensável exige critérios explícitos, controles de viés e, idealmente, calibração humana (ZHENG et al., 2023; WANG et al., 2023); a ausência dessa calibração limita o experimento. A avaliação separa a relevância e a fidelidade ao contexto da qualidade da resposta (ES et al., 2024).

A quarta atividade é a atribuição de falhas, que converte notas em diagnóstico acionável. Cada resposta incorreta é classificada por modo, que pode ser recuperação, raciocínio, ingestão ou citação, e cruzada com a taxa de acerto da fonte exigida. É o que permite dizer ao cliente, por exemplo, que as falhas do RAG são majoritariamente de citação, seis de oito, corrigíveis com um melhor prompt de atribuição, e que as do SQL são de recuperação, dez de doze, estruturais, porque o fato vive em prosa e não em tabela. A quinta atividade é recomendar arquitetura e roadmap, sintetizando as métricas no mapa de tarefa para arquitetura e no plano híbrido de implementação, conforme as seções 4 e 6.

Fechando o ciclo, a reavaliação na escala é a atividade recorrente, que consiste em reexecutar o benchmark à medida que a base cresce, porque a arquitetura ótima é função da escala atual, tanto que o custo do contexto completo cresce de forma linear e a precisão de citação do RAG decai com o acúmulo de distratores, enquanto o wiki se mantém. Essa atividade sustenta a receita de assinatura da seção 7 e só é economicamente viável porque reaproveita o pipeline de avaliação, o recurso principal da empresa descrito na seção 8. O conjunto das atividades é, em essência, engenharia de avaliação aplicada à decisão de arquitetura, que é a competência que a ContextLab vende.

10. REDE DE PARCEIROS ESTRATÉGICOS

As parcerias da ContextLab cobrem aquilo que a empresa deliberadamente não internaliza, que é a infraestrutura de modelos e de computação, o acesso ao mercado e o respaldo metodológico. Como o serviço é de diagnóstico, ou seja, medir e recomendar, e não hospedar a solução do cliente, essas parcerias permitem operar com uma estrutura enxuta e manter o foco no recurso que de fato diferencia a empresa, que é o método de avaliação.

A primeira categoria são os provedores de modelos e de embeddings, acessados via agregadores de API, como o OpenRouter usado no experimento. São eles que fornecem os modelos sob teste, os modelos de raciocínio mais fortes usados na verificação de robustez, os juízes para a avaliação cega e os modelos de embedding que sustentam o RAG semântico (REIMERS; GUREVYCH, 2019; KARPUKHIN et al., 2020). A parceria é crítica em disponibilidade e em diversidade de modelos, pois poder testar o mesmo benchmark em modelos diferentes foi o que

permitiu mostrar que a fraqueza do SQL é arquitetural, já que ela persiste de gemini-3.1-flash-lite a deepseek-v4-pro, e não um limite de capacidade do modelo mais barato. O custo dessa parceria é operacional e modesto, e o risco de dependência é mitigado pelo desenho neutro do pipeline, que troca de modelo sem reescrever o método.

A segunda categoria é a infraestrutura de nuvem e de busca vetorial, necessária para executar o pipeline, armazenar os corpora e índices e servir a busca por similaridade em escala, sendo a viabilidade da busca vetorial em escala de bilhões de vetores um resultado já estabelecido (JOHNSON; DOUZE; JÉGOU, 2019). Para a ContextLab, essa camada é commodity, pois o volume é o de avaliação, e não o de produção contínua de um assistente, de modo que a parceria de nuvem é um custo controlável e substituível.

A terceira categoria são os integradores de sistemas, que constituem o canal de escala da seção 5 e, ao mesmo tempo, uma parceria estratégica. Integradores que implantam plataformas de IA empresarial têm interesse direto em reduzir o risco de arquitetura dos seus projetos, e o diagnóstico da ContextLab é um insumo que faz isso. A parceria é simbiótica, pois o integrador ganha um argumento técnico defensável para as suas escolhas e um terceiro independente para validá-las, enquanto a ContextLab ganha acesso a clientes que chegariam por meio de projetos maiores de implantação.

A quarta categoria são os parceiros acadêmicos. O método da ContextLab é, na origem, um experimento controlado com avaliação cega por modelo e revisão por segundo modelo, ancorado em literatura revisada por pares sobre recuperação aumentada, GraphRAG, texto-para-SQL, perda no meio do contexto e avaliação de LLMs (LEWIS et al., 2020; EDGE et al., 2024; LIU et al., 2024; ZHENG et al., 2023). Manter proximidade com a pesquisa preserva o diferencial técnico, que é acompanhar o estado da arte das estratégias, sem o qual a comparação perde sentido, e dá respaldo de credibilidade ao laudo perante clientes em setores que exigem rigor metodológico.

As quatro categorias se distribuem por função, sendo os provedores de modelos e de nuvem o insumo operacional, os integradores o alcance de mercado e os parceiros acadêmicos o respaldo e a atualização do método. Nenhuma delas captura o núcleo de valor, que é o pipeline de avaliação e a equipe de engenharia de contexto, o que mantém o poder de barganha da ContextLab e preserva a tese central

do negócio, de que o valor está em medir com rigor, e de que as parcerias apenas suprem o que cerca essa medição.

11. ESTRUTURA DE CUSTOS DA EMPRESA

A estrutura de custos de uma arquitetura de contexto só se torna compreensível quando se separa o custo de construção, que é único e pago para montar a estrutura, do custo de execução, que é recorrente e pago a cada consulta. Essa separação é o coração do que a ContextLab mede e recomenda, porque é justamente nesse ponto que a intuição de mercado falha: a estratégia sem custo de construção, o contexto completo, é a mais cara de operar, enquanto a estratégia com maior custo de construção, o wiki, é uma das mais baratas de operar. A Tabela 3 reúne os números medidos no experimento.

Tabela 3. Economia de construção versus execução por estratégia (corpus base, 40 questões).

Estratégia	Chamadas LLM (build)	Custo de build	Complexidade de build	Custo de execução / consulta	Custo de execução / 40q	Latência média
Contexto completo	0	US\$ 0,0000	nenhuma	US\$ 0,0330	US\$ 1,336	4,3 s
RAG semântico	0 (embeddings)	~US\$ 0,0024	baixa	US\$ 0,0020	US\$ 0,065	2,3 s
Wiki (GraphRAG)	13	US\$ 0,0311	média a alta	US\$ 0,0030	US\$ 0,123	3,8 s
SQL (texto-para-SQL)	0 (ETL determinístico)	US\$ 0,0000	alta (desenho de esquema)	US\$ 0,0030	US\$ 0,107	3,0 s

Fonte: elaborado pelo autor com base nos resultados do experimento.

O contexto completo é o caso mais ilustrativo. Ele não tem etapa de construção, com custo de build de US\$ 0, mas tem o maior custo de execução, de US\$ 0,033 por consulta, que é cerca de dez a dezesseis vezes o das demais estratégias, situadas entre US\$ 0,002 e US\$ 0,003 por consulta. A razão é estrutural, pois cada consulta reenvia o corpus inteiro ao modelo, de modo que o custo é proporcional ao tamanho da base e se paga de novo a cada pergunta. É o que faz o seu custo crescer de forma linear com a escala, de US\$ 1,336 para US\$ 2,340 e depois US\$ 3,341 por 40 questões entre 1x e 3x, como mostra a Figura 2, na Proposta de Valor. A literatura sustenta o mecanismo, pois colocar todo o corpus no prompt escala em tokens, custo e latência sem garantir um uso robusto do contexto, e o custo de inferência deve entrar de forma explícita na comparação de arquiteturas (POPE et al., 2023; SARDANA et al., 2024).

O RAG semântico é o mais barato de ponta a ponta. O seu custo de construção é quase nulo, de cerca de US\$ 0,0024, referente apenas à geração de embeddings, e o seu custo de execução é o menor, de US\$ 0,002 por consulta e US\$ 0,065 por 40 questões, porque ele recupera poucos trechos relevantes em vez de reenviar o corpus. O wiki representa a troca oposta, e mais interessante para o negócio, pois paga um custo de construção modesto de LLM, de US\$ 0,031 para gerar treze nós de tópico, e, em troca, executa de forma barata, a US\$ 0,003 por consulta, com o perfil de falhas mais limpo e a melhor citação. O banco do agente SQL é construído por um processo determinístico de extração de tabelas, sem custo de LLM, de US\$ 0, mas concentra o esforço no desenho do esquema, complexidade de construção alta que não aparece como custo monetário, e sim como trabalho de engenharia. Em resumo, o wiki e o SQL trocam maior complexidade de construção por um custo de execução baixo e estável.

Cabe um esclarecimento de escopo a respeito do custo de construção. As três estratégias que estruturam o contexto, ou seja, RAG, wiki e SQL, exigem, na prática, alguma etapa de pré-processamento dos dados, que pode envolver a geração de embeddings, a transformação do corpus em nós por meio de agentes de IA, ou um caminho determinístico mais barato e rápido, como a extração direta de tabelas. Este experimento mede o custo de construção apenas no formato em que cada estratégia foi implementada aqui, e não explora o espaço completo de alternativas de pré-processamento, o que escaparia ao escopo do trabalho. Vale registrar, no entanto, que, dependendo das escolhas específicas de pré-processamento, tanto o custo total quanto a acurácia podem variar, e que a latência de pré-processamento é assumida como irrelevante, por ser um custo único e fora do caminho de resposta a cada consulta.

Há um custo que a tabela monetária não captura, mas que a ContextLab inclui na análise, que é o custo de latência. O contexto completo é também o mais lento, com 4,3 s por consulta, porque processa a entrada maior, enquanto o RAG é o mais rápido, com 2,3 s; o wiki e o SQL ficam no meio, pois os seus pipelines agênticos de múltiplas chamadas adicionam latência, mas mantêm o custo uma ordem de grandeza abaixo do contexto completo, conforme a Figura 6. Para um assistente de alto volume, a latência é parte do custo total de propriedade, e a comparação correta é qualidade por custo, incluindo o tempo, e não a acurácia máxima isolada (SARDANA et al., 2024; LIU et al., 2024).




Figura 6. Latência média por questão e custo de execução por 40 questões, por estratégia, no corpus base (custo em escala logarítmica).

Essa estrutura de custos se conecta diretamente à precificação do serviço, tratada na seção 7. O diagnóstico da ContextLab é, em si, barato de produzir, pois avaliar 40 questões em quatro estratégias custa poucos dólares em chamadas de modelo, e o pipeline é reutilizável, de modo que a margem do serviço é alta e o custo marginal de uma reavaliação é baixo, o que viabiliza a assinatura recorrente. Para o cliente, o valor do laudo está precisamente em quantificar e tornar previsível o custo de execução que ele pagará por anos, pois, ao recomendar o wiki em vez do contexto completo numa base que cresce, a ContextLab desloca o cliente de um custo de execução que cresce sem limite para um custo plano de uma ordem de grandeza menor, economia que se acumula a cada consulta e a cada documento adicionado à base.

REFERÊNCIAS

- DAVENPORT, Thomas H.; PRUSAK, Laurence. *Working knowledge: how organizations manage what they know*. Boston: Harvard Business School Press, 1998. ISBN 1-57851-301-4.
- EDGE, Darren et al. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. arXiv, 2024. Disponível em: <https://arxiv.org/abs/2404.16130>. DOI: 10.48550/arXiv.2404.16130.
- ES, Shahul et al. RAGAs: Automated Evaluation of Retrieval Augmented Generation. In: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. St. Julians: Association for Computational Linguistics, 2024. p. 150-158. DOI: 10.18653/v1/2024.eacl-demo.16.
- GAO, Yunfan et al. *Retrieval-Augmented Generation for Large Language Models: A Survey*. arXiv, 2023. Disponível em: <https://arxiv.org/abs/2312.10997>. DOI: 10.48550/arXiv.2312.10997.
- Jl, Ziwei et al. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, v. 55, n. 12, art. 248, 2023. DOI: 10.1145/3571730.

JOHNSON, Jeff; DOUZE, Matthijs; JÉGOU, Hervé. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, v. 7, n. 3, p. 535-547, 2019. DOI: 10.1109/TBDATA.2019.2921572.

KARPUKHIN, Vladimir et al. Dense Passage Retrieval for Open-Domain Question Answering. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. Online: Association for Computational Linguistics, 2020. p. 6769-6781. DOI: 10.18653/v1/2020.emnlp-main.550.

LEWIS, Patrick et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: *Advances in Neural Information Processing Systems 33*. 2020. p. 9459-9474. DOI: 10.48550/arXiv.2005.11401.

LI, Jinyang et al. Can LLM Already Serve as A Database Interface? A Blg Bench for Large-Scale Database Grounded Text-to-SQLs. In: *Advances in Neural Information Processing Systems 36: Datasets and Benchmarks Track*. 2023.

LIU, Nelson F. et al. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, v. 12, p. 157-173, 2024. DOI: 10.1162/tacl_a_00638.

LIU, Pengfei et al. Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing. *ACM Computing Surveys*, v. 55, n. 9, p. 1-35, 2023. DOI: 10.1145/3560815.

MIN, Sewon et al. FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Singapore: Association for Computational Linguistics, 2023. p. 12076-12100. DOI: 10.18653/v1/2023.emnlp-main.741.

NONAKA, Ikujiro. A Dynamic Theory of Organizational Knowledge Creation. *Organization Science*, v. 5, n. 1, p. 14-37, 1994. DOI: 10.1287/orsc.5.1.14.

PENG, Boci et al. Graph Retrieval-Augmented Generation: A Survey. *ACM Transactions on Information Systems*, 2025. DOI: 10.1145/3777378.

POPE, Reiner et al. Efficiently Scaling Transformer Inference. In: *Proceedings of the 6th Conference on Machine Learning and Systems*. Miami Beach: MLSys, 2023.

RAJKUMAR, Nitarshan; LI, Raymond; BAHADANAU, Dzmitry. *Evaluating the Text-to-SQL Capabilities of Large Language Models*. arXiv, 2022. Disponível em: <https://arxiv.org/abs/2204.00498>. DOI: 10.48550/arXiv.2204.00498.

REIMERS, Nils; GUREVYCH, Iryna. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*. Hong Kong: Association for Computational Linguistics, 2019. p. 3982-3992. DOI: 10.18653/v1/D19-1410.

RIBEIRO, Marco Tulio et al. Beyond Accuracy: Behavioral Testing of NLP Models with CheckList. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Online: Association for Computational Linguistics, 2020. p. 4902-4912. DOI: 10.18653/v1/2020.acl-main.442.

SAHOO, Pranab et al. A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications. arXiv, 2024. Disponível em: <https://arxiv.org/abs/2402.07927>. DOI: 10.48550/arXiv.2402.07927.

SARDANA, Nikhil et al. *Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws*. arXiv, 2024. Disponível em: <https://arxiv.org/abs/2401.00448>. DOI: 10.48550/arXiv.2401.00448.

SARTHI, Parth et al. *RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval*. arXiv, 2024. Disponível em: <https://arxiv.org/abs/2401.18059>. DOI: 10.48550/arXiv.2401.18059.

WANG, Peiyi et al. *Large Language Models are not Fair Evaluators*. arXiv, 2023. Disponível em: <https://arxiv.org/abs/2305.17926>. DOI: 10.48550/arXiv.2305.17926.

WANG, Yu et al. Knowledge Graph Prompting for Multi-Document Question Answering. *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 38, n. 17, p. 19206-19214, 2024. DOI: 10.1609/aaai.v38i17.29889.

YU, Tao et al. Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task. In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*. Brussels: Association for Computational Linguistics, 2018. p. 3911-3921. DOI: 10.18653/v1/D18-1425.

ZHENG, Lianmin et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In: *Advances in Neural Information Processing Systems 36: Datasets and Benchmarks Track*. 2023.

ANEXOS

Os anexos reúnem o detalhamento metodológico e as tabelas e figuras completas que sustentam os resultados resumidos nas seções 2, 4 e 11.

Anexo A. Metodologia detalhada

O experimento avaliou quatro estratégias de engenharia de contexto sobre um corpus sintético controlado de uma empresa fictícia de educação corporativa, a NovaLearn, com 32 documentos no tamanho base. O uso de um corpus sintético é uma escolha metodológica deliberada, pois permite congelar as respostas canônicas e garantir, por construção, que o material adicionado nos testes de escala não altere o gabarito, controle que dados reais não ofereceriam com a mesma segurança. As quatro estratégias compartilharam o mesmo corpus, o mesmo conjunto de 40 questões de avaliação congeladas, o mesmo modelo primário (google/gemini-3.1-flash-lite, com janela de 1 milhão de tokens e temperatura 0) e a mesma instrução de estilo de resposta; os prompts e o corpus foram congelados e identificados por hash (prompt_version, corpus_version).

Estratégias, conforme implementadas:

- Contexto completo. O corpus inteiro limpo, com doc_id e section_id estáveis e metadados de autoridade, é colocado no prompt, e o modelo responde com citações.
- RAG semântico. As seções são fragmentadas, com alvo de cerca de 850 palavras e sobreposição, embutidas com openai/text-embedding-3-small e recuperadas por similaridade de cosseno (top-8); os embeddings determinísticos são cacheados.
- Wiki ou grafo de conhecimento, no estilo GraphRAG. Na construção, o LLM gera um nó por tópico que preserva fatos, com cada nó citando seções brutas (NL-XXX#NL-XXX-SYY) e obrigado a preservar todos os números de forma literal, além de um índice de entidades. Na resposta, uma travessia agêntica limitada seleciona até 3 nós-semente, segue até 5 nós relacionados e expande até 8 seções brutas para recuperar fatos exatos, e então responde com citações.
- SQL ou banco estruturado, com agente texto-para-SQL. Na construção, um ETL determinístico de tabelas markdown carrega as tabelas reais do corpus em tabelas relacionais com proveniência, cobrindo preços, métricas de segmento,

tickets de suporte, adoção de funcionalidades e cronogramas, além de documents e uma tabela de texto integral sections; cada linha curada carrega authority_level, doc_status, publication_date e source_section. Na resposta, um agente texto-para-SQL escreve a consulta, executa-a em conexão somente leitura, com guarda de SELECT apenas, autocorrigue até 4 vezes em caso de erro ou resultado vazio, e sintetiza uma resposta citada. Não há alucinação de extração porque o ETL copia as células de forma literal.

Modelos. O primário sob teste é o google/gemini-3.1-flash-lite, usado em todas as comparações de 40 por 4. O segundo modelo, de robustez, é o deepseek/deepseek-v4-pro, executado nas 12 questões mais difíceis por 4 estratégias. O modelo do limite de viabilidade é o openai/gpt-oss-120b:free, com 131 mil tokens de contexto, usado apenas para demonstrar o limite do contexto completo. A avaliação é feita por um modelo de linguagem do estado da arte, mais forte do que os modelos sob teste.

Avaliação cega por modelo, com critérios do autor e revisão por segundo modelo. Cada resposta foi avaliada, de forma cega quanto à estratégia que a gerou, por Claude Sonnet, um modelo de linguagem mais forte do que o modelo sob teste, contra um gabarito definido pelo autor, ou seja, a resposta esperada, as fontes e seções exigidas e o conjunto canônico de fatos de cada questão, na escala de 0 a 3 para acurácia, completude, citação, utilidade e tratamento de risco, além da contagem de afirmações não sustentadas e da atribuição da falha a uma de quatro causas (recuperação, raciocínio, ingestão ou citação). Todas as respostas sinalizadas foram revisadas por Claude Opus como segundo modelo, com atenção especial às notas mais baixas, que esse passe confirmou como falhas genuínas, e não como artefatos de avaliação. Nenhuma pessoa avaliou ou auditou as respostas do v1. Esse desenho aplica critérios explícitos e cegamento (ZHENG et al., 2023; WANG et al., 2023), mas a ausência de calibração humana permanece uma ameaça à validade. A avaliação separa a relevância e a fidelidade ao contexto da qualidade da resposta (ES et al., 2024; MIN et al., 2023).

Estudo de escalabilidade controlada. Para medir a deterioração com o crescimento do corpus, este foi expandido para cerca de 2x, com 64 documentos, e 3x, com 96 documentos, mantendo fixas as 40 questões e as suas respostas canônicas. Os documentos distratores adicionados introduzem ruído de recuperação, mas nenhum fato novo, e são comprovadamente não contaminantes, pois um gerador

determinístico por template, com portão de validação, garante que nenhum corpo de documento contenha cifrao, porcentagem, número, nome de entidade canônica ou data de roadmap, e todos têm authority_level menor ou igual a 3, de modo a nunca superarem fontes canônicas. A entrada do contexto completo cresceu, assim, de cerca de 131 mil para 232 mil e 332 mil tokens, ou cerca de 2,5x. O desenho com distratores e casos controlados segue a tradição de teste comportamental que vai além da acurácia agregada (RIBEIRO et al., 2020; LIU et al., 2024).

Anexo B. Tabelas completas do estudo de escala (1x para 3x)

Tabela B.1. Acurácia (0 a 3) por escala.

Estratégia	1x	2x	3x	Tendência
Contexto completo	2,95	2,80	2,90	aproximadamente estável
RAG semântico	2,925	2,70	2,675	declínio gradual
Wiki (GraphRAG)	2,95	2,85	2,85	mais robusto
SQL (texto-para-SQL)	2,35	2,00	2,20	estável e ruidoso

Tabela B.2. Citação (0 a 3) por escala.

Estratégia	1x	2x	3x
Contexto completo	2,675	2,05	2,425
RAG semântico	2,70	2,325	2,35
Wiki (GraphRAG)	2,75	2,70	2,725
SQL (texto-para-SQL)	1,625	1,45	1,725

Tabela B.3. Taxa de acerto de recuperação, da fonte exigida, por escala.

Estratégia	1x	2x	3x
Contexto completo	1,00	1,00	1,00
RAG semântico	0,70	0,65	0,65
Wiki (GraphRAG)	0,775	0,725	0,775
SQL (texto-para-SQL)	0,425	0,325	0,375

Tabela B.4. Custo por 40 questões, em dólares, por escala.

Estratégia	1x	2x	3x
Contexto completo	1,336	2,340	3,341
RAG semântico	0,065	0,060	0,060
Wiki (GraphRAG)	0,123	0,120	0,121
SQL (texto-para-SQL)	0,107	0,085	0,091

Tabela B.5. Tokens médios de entrada por escala.

Estratégia	1x	2x	3x
Contexto completo	131.014	231.843	331.937
RAG semântico	4.554	4.207	4.153
Wiki (GraphRAG)	9.024	8.793	8.930
SQL (texto-para-SQL)	8.965	6.870	7.487

Tabela B.6. Latência média, em milissegundos, por escala.

Estratégia	1x	2x	3x
Contexto completo	4.326	4.281	5.181
RAG semântico	2.272	2.767	3.027
Wiki (GraphRAG)	3.786	3.519	3.624
SQL (texto-para-SQL)	2.998	3.140	2.935

Fonte: elaborado pelo autor com base nos resultados do experimento.

Anexo C. O limite de viabilidade do contexto completo (modelo de 131k)

Os mesmos três tamanhos de corpus foram executados em um modelo com janela de 131 mil tokens. O contexto completo falhou em todas as escalas, inclusive em 1x, porque o prompt já excede a janela, enquanto o RAG permaneceu viável em 1x, 2x e 3x. No modelo primário de 1 milhão de tokens o contexto completo ainda executa, mas a sua viabilidade depende de uma janela cada vez maior, propriedade que as estratégias de recuperação não exigem.

Tabela C.1. Viabilidade em modelo de contexto de 131k (8 questões por célula).

Escala	Contexto completo	RAG semântico
1x	N/A (contexto excedido)	viável
2x	N/A (contexto excedido)	viável
3x	N/A (contexto excedido)	viável

Anexo D. Robustez com segundo modelo (12 questões mais difíceis)

Executar as doze questões mais difíceis em um modelo de raciocínio mais forte (deepseek-v4-pro) eleva a acurácia do contexto completo de 2,83 para 2,92 e a sua citação de 2,42 para 2,58, e melhora ligeiramente as demais. O wiki já está próximo do teto em ambos os modelos, em 2,92, e o SQL permanece em torno de 2,42 independentemente do modelo, o que confirma que a fraqueza do SQL é arquitetural, e não uma deficiência do modelo mais barato.

Tabela D.1. Comparação entre modelos no subconjunto difícil (acurácia e citação).

Estratégia	gemini-3.1-flash-lite	deepseek-v4-pro
Contexto completo	2,833 / 2,417	2,917 / 2,583
RAG semântico	2,833 / 2,500	2,833 / 2,583
Wiki (GraphRAG)	2,917 / 2,917	2,917 / 2,833
SQL (texto-para-SQL)	2,417 / 1,500	2,417 / 1,750

Fonte: elaborado pelo autor com base nos resultados do experimento.

Anexo E. Análise de falhas e desempenho por categoria

Tabela E.1. Atribuição de falhas (40 questões) e taxa de acerto da fonte exigida.

Estratégia	Recuperação	Raciocínio	Citação	Total de falhas	Taxa de acerto
Contexto completo	1	1	0	2	1,00
RAG semântico	2	0	6	8	0,70

Estratégia	Recuperação	Raciocínio	Citação	Total de falhas	Taxa de acerto
Wiki (GraphRAG)	1	0	0	1	0,775
SQL (texto-para-SQL)	10	0	2	12	0,425

Tabela E.2. Acurácia por categoria de questão.

Categoria	Contexto completo	RAG	Wiki	SQL
Busca direta de fato	3,00	3,00	3,00	1,50
Citação e evidência	3,00	3,00	3,00	2,80
Síntese entre documentos	3,00	3,00	3,00	3,00
Comparação	2,80	2,80	2,80	2,60
Orientação procedural	3,00	2,60	3,00	2,00
Contradição e atualidade	3,00	3,00	3,00	2,33
Estruturada / SQL-friendly	3,00	3,00	3,00	2,20
Recomendação de negócio	2,50	3,00	2,50	2,50

Fonte: elaborado pelo autor com base nos resultados do experimento.

Anexo F. Figuras complementares de escala

As Figuras 1 e 2 aparecem na Proposta de Valor, a Figura 6 na Estrutura de Custos da Empresa, e as Figuras 7 e 8 na Descrição do Produto ou Serviço. As três figuras a seguir detalham o comportamento das estratégias sob crescimento do corpus, complementando as tabelas do Anexo B.




Figura 3. Acurácia (0 a 3) versus escala do corpus. O wiki é o mais robusto; o RAG declina de forma gradual; o contexto completo permanece aproximadamente estável em acurácia.




Figura 4. Qualidade de citação (0 a 3) versus escala do corpus. A citação do wiki se mantém estável, enquanto a do contexto completo se degrada à medida que o ruído aumenta.




Figura 5. Taxa de acerto da fonte exigida versus escala do corpus. O wiki preserva a cobertura de recuperação, ao passo que a do RAG cai e permanece baixa.

Anexo G. Nota sobre avaliação e ameaças à validade

As notas são assistidas por modelo de linguagem, e a sua confiabilidade foi tratada com três cuidados. Primeiro, foi definida uma diretriz de avaliação firme e explícita, com a resposta esperada, as fontes e seções exigidas e um conjunto canônico de fatos por questão, de modo que a avaliação fosse feita contra um gabarito objetivo, e não por impressão. Segundo, a avaliação foi conduzida por um modelo do estado da arte, mais forte do que o modelo sob teste, e de forma cega quanto à estratégia que gerou cada resposta. Terceiro, todas as respostas sinalizadas foram revisadas por Claude Opus como segundo modelo, com atenção especial às notas mais baixas do SQL. Esse passe confirmou falhas genuínas, como o recurso de busca textual do agente deixando de recuperar fatos que vivem em seções narrativas, e não artefatos de avaliação. Nenhuma pessoa avaliou ou auditou as respostas do v1; a ausência de calibração humana é uma ameaça à validade.

As execuções são únicas e determinísticas, com temperatura 0, de modo que intervalos de confiança não são reportados. Os distratores são gerados de forma determinística por template, o que os torna menos variados linguisticamente do que texto humano, embora isso não afete o seu papel como ruído de recuperação, e o determinismo reforça a reprodutibilidade e a garantia de não contaminação. O

multiplicador de 3x refere-se à contagem de documentos, e o múltiplo de tokens correspondente é reportado nas tabelas, ficando um pouco abaixo de 3x porque os documentos base são longos. O custo de construção é medido apenas no formato em que cada estratégia foi implementada aqui; escolhas diferentes de pré-processamento, como outros modelos de embedding ou outras formas de gerar os nós, poderiam deslocar tanto o custo total quanto a acurácia, e essa exploração está fora do escopo deste trabalho. Por fim, os resultados caracterizam estas implementações de cada estratégia, e uma implementação diferente poderia deslocar os números absolutos, ainda que se espere que os trade-offs qualitativos se mantenham.